

6. naloga – Luščenje modelskih parametrov in razdelčni modeli

Žiga Šircelj
28222072

1 Farmakologija

Prilagajamo funkcijo

$$y = \frac{y_0 x}{x + a} \quad (1)$$

na podatke z metodo minimizacije količine χ^2


$$\chi^2 = \sum_{i=1}^N \frac{(y_i - f(x_i, \vec{a}))^2}{\sigma_i^2} = \min., \quad (2)$$

kjer so x_i, y_i pari izmerkov, σ_i napake izmerkov y_i , f funkcija, ki jo prilagajamo, $\vec{a}$ vektor parametrov v f (y_0 in a) in N število izmerkov. Uporabil sem Scipy funkcijo `least_squares` z algoritmom Levenberg-Marquardt. Problem lahko lineariziramo:


$$f(x) = \frac{1}{y} = \frac{1}{y_0} + \frac{ax}{y_0} \quad (3)$$

$$\sigma\left(\frac{1}{y}\right) = \frac{\sigma(y)}{y^2} \quad (4)$$

in dobimo krivuljo na sliki 1. Krivulja je dobra in napake v parametrih niso hude. Na sliki 2 je prikazana kovariančna matrika za parametra y_0 in a .




Slika 1: Izmerki in prilagojena krivulja.




Slika 2: Kovariančna matrika.

Če dodamo še odvode po parametrih (Jakobijan), dobimo rezultat na slikah 3 in 4. Ta krivulja izgleda v redu. Nenavadni sta ogromni napaki za y_0 in a . Verjetno samo ne razumem dokumentacije za kako upoštevati tudi odvode.



Slika 3: Izmerki in prilagojena krivulja.




Slika 4: Kovariančna matrika.


Razširjen nelinearen model je oblike

$$y = \frac{y_0 x^p}{a^p + x^p}, \quad (5)$$

kjer je p nov parameter. Rezultat je na slikah 5 in 6. V primerjavi s primerom, ko je $p = 1$, se na oko malo bolje prilega. Zanimivo je, da je napaka v y_0 večja, v a pa manjša, χ^2 je pa večji. Korelacije med parametri so $\rho(y_0, a) = 0.706$, $\rho(y_0, p) = -0.596$ in $\rho(a, p) = -0.582$. Kot prej, če upoštevam še odvode, postanejo napake nesmiselne.



Slika 5: Izmerki in prilagojena krivulja z novim parametrom p .



Slika 6: Kovariančna matrika.

2 Ledvice

Iščemo najboljši model za učinkovitost ledvic iz podatkov (sunki na detektorju v odvisnosti od časa). Modeli so narisani na sliki 7. Izhodišče je eksponentna funkcija

$$f_1(t) = c_1 e^{-\lambda_1 t} \quad (6)$$

Ta se precej slabo prilega, zato poskusimo dodati konstanten člen


$$f_2(t) = c_1 e^{-\lambda_1 t} + B. \quad (7)$$

Dobimo malenkost boljšo krivuljo. Če uporabimo dvorazdelčni model

$$f_3(t) = c_1 e^{-\lambda_1 t} + c_2 e^{-\lambda_2 t} \quad (8)$$

$$f_4(t) = c_1 e^{-\lambda_1 t} + c_2 e^{-\lambda_2 t} + B, \quad (9)$$

je rezultat zelo zadovoljiv z in brez konstantnega člena. Funkcija f_4 nam res da manjši χ^2 , vendar so napake v parametrih za f_3 manjše, saj ima manj parametrov.



Slika 7: Prilagojene krivulje in kovariančne matrike.

f_i	χ^2	c_1	$\lambda_1[10^{-4}]$	B	c_2	$\lambda_2[10^{-4}]$
f_1	2029	8895 ± 44	8.098 ± 0.052			
f_2	260.6	9829 ± 75	25.04 ± 0.31	2438 ± 18		
f_3	36.29	8177 ± 120	47.52 ± 1.367		5231 ± 98	4.169 ± 0.122
f_4	19.97	6096 ± 335	69.60 ± 4.93	1843 ± 87	5715 ± 271	12.38 ± 0.98

3 Magnetni spektrometer

Zanima nas preslikava iz točke na detektorju, kjer delec konča, v kot prileta delca v magnetno polje

$$(x_{fp}, \theta_{fp}) \mapsto \theta_{tg}, \quad (10)$$

kjer je x_{fp} položaj na detektorju, θ_{fp} kot na detektorju in θ_{tg} kot tarče. Model za to je polinom za θ_{fp} in x_{fp} :

$$\theta_{tg} = a_0 + a_1 x_{fp} + a_2 \theta_{fp} + a_3 x_{fp} \theta_{fp} + a_4 x_{fp}^2 + a_5 \theta_{fp}^2 + \dots \quad (11)$$

Ker je število meritev N mnogo večja od število parametrov M (predoločen sistem), je χ^2 slabo orodje, zato raje uporabimo razcep na singularne vrednosti (SVD). Sistem enačb 11 zapišemo kot


$$\mathbf{A} \vec{a} = \vec{b}, \quad (12)$$

kjer so $\vec{a}$ vektor parametrov $a_0, a_1, \dots$, $\vec{b}$ vektor meritev θ_{tg} in $\mathbf{A}$ matrika vrednosti na desni strani. SVD razcep matrike A je


$$\mathbf{A} = \mathbf{U} \mathbf{W} \mathbf{V}^T, \quad (13)$$

kjer je $\mathbf{U}$ ortogonalna matrika velikosti $N \times M$, $\mathbf{W}$ diagonalna matrika singularnih vrednosti w_i velikosti $M \times M$ in $\mathbf{V}$ ortogonalna matrika velikosti $M \times M$. Potem je vektor parametrov $\vec{a}$ kar


$$\vec{a} = \sum_{i=1}^M \left(\frac{\vec{U}_i \cdot \vec{b}}{w_i} \right) \vec{V}_i. \quad (14)$$




Slika 8: Prilagojene točke in kovariančna matrika.




Slika 9: Prilagojene točke in kovariančna matrika.




Slika 10: Prilagojene točke in kovariančna matrika.



Slika 11: Prilagojene točke in kovariančna matrika.



Slika 12: Prilagojene točke in kovariančna matrika.



Slika 13: Singularne vrednosti zadnjega primera.